Desarrollo de un sistema de recomendaciones de carreras e instituciones universitarias para estudiantes que aspiran a la educación superior en Ecuador

Patricia Lema
Maestría en Ciencia de Datos
Universidad San Francisco de Quito

Objetivo

- Diseñar un sistema de recomendación que utilice SVD para identificar afinidades entre postulantes y programas académicos, con el propósito de orientar a los estudiantes hacia carreras compatibles con su perfil y aumentar sus probabilidades de éxito en el proceso de admisión.

Contexto

- Elegir una carrera universitaria es una decisión crítica.
- Muchas decisiones se toman con información incompleta.
- Existe deserción universitaria significativa en los primeros años.
- Se propone usar análisis de datos para apoyar la orientación académica.

Problema

- Muchos postulantes seleccionan carreras sin considerar su afinidad académica.
- Esto puede generar:
  - Decisiones basadas en percepción y no en datos.
  - Selecciones académicas poco alineadas con el perfil del estudiante.
  - Dificultad para identificar opciones universitarias potencialmente relevantes.

Justificación

- El análisis de datos históricos permite identificar qué carreras podrían ser más compatibles con el perfil de cada estudiante
- Un sistema de recomendación basado en SVD puede:
  - Identificar patrones entre postulantes con características similares,
  - Sugerir opciones con mayor afinidad,
  - Reducir la incertidumbre en la toma de decisiones académicas,
  - Apoyar a los estudiantes en un proceso altamente competitivo.
- Esto contribuye a mejorar el acceso a información relevante y apoyar decisiones académicas más informadas.

Metodología

- Dataset
- Preprocesamiento de datos y calidad de la información
- Modelo de recomendación basado en SVD
- Selección del número de factores latentes
- Generación de recomendaciones, validación y baselines

Metodología

Dataset

- 218,766 estudiantes
- 1.5 millones de registros de postulación
- 352 programas universitarios
- 218 instituciones
- 24 provincias del Ecuador
- Periodo: septiembre - octubre de 2021.

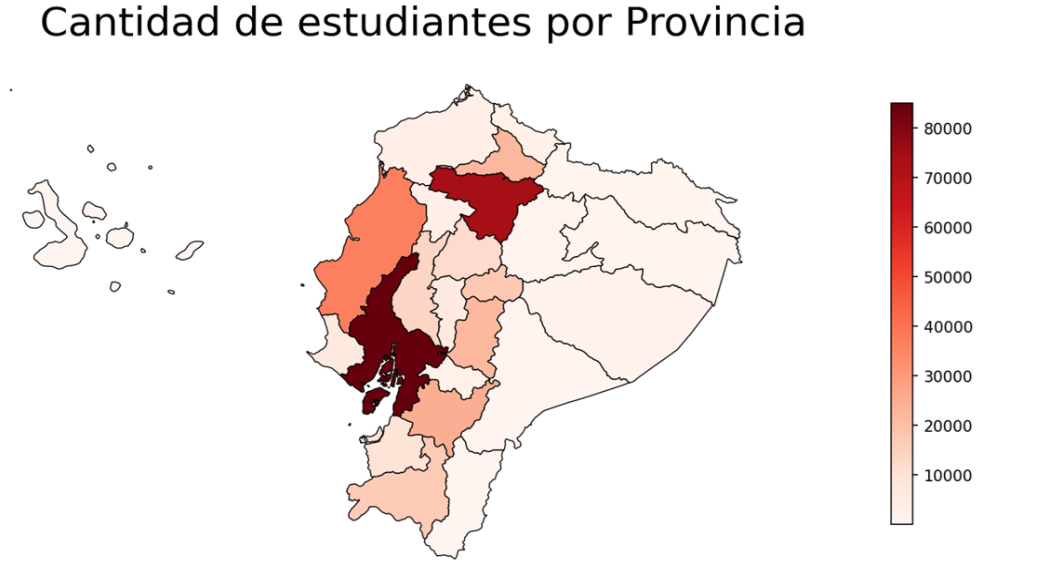

Metodología

Preprocesamiento de datos y calidad de la información

- Fuente: 3 archivos csv
  - primera.csv
  - segunda.csv
  - tercera.csv
- Se estandarizaron formatos de fecha
- Análisis exploratorio (EDA)
  - Distribución de puntajes de postulación.
  - Conteo de estudiantes por provincia, carreras e instituciones.
  - Visualizaciones: barras, líneas y comparaciones geográficas.

Metodología

Modelo de recomendación basado en SVD

- Singular Value Decomposition: es una técnica matemática que descompone una matriz grande en factores más pequeños para descubrir patrones ocultos.
- Fórmula: $$\mathbf{R} = \mathbf{U}\boldsymbol{\Sigma}\mathbf{V}^\top$$
  - La matriz de interacciones estudiante–programa se factoriza para identificar factores latentes de preferencia.
  - Estos factores permiten estimar la afinidad entre estudiantes y programas y generar rankings personalizados de recomendaciones.

Metodología

Construcción del dataset del recomendador

- Se creó una tabla final df_students_courses con:
  - Estudiante (INS_ID)
  - Institución
  - Carrera

- Cada combinación Institución–Carrera representa un ítem del sistema de recomendación.
- Matriz: usuario–ítem.

Metodología

Selección del número de factores latentes

- Se evaluaron valores de k entre 20 y 150.
- El desempeño se midió con Precision@10, Recall@10 y NDCG@10 bajo Leave-One-Out.
- Las métricas se reportan con intervalos de confianza al 95 % (IC 95 %).

Metodología

Generación de recomendaciones, validación y baselines

- Se utilizó Leave-One-Out, ocultando una postulación real por estudiante para evaluar si el modelo logra recuperarla
- La evaluación mide la capacidad del sistema para recomendar opciones académicas relevantes no vistas durante el entrenamiento.
- Se comparó el modelo con dos baselines:
  - Popularidad: recomienda los programas con más postulaciones.
  - Aleatorio: selecciona programas al azar.
- Comparación con otros modelos:
  - Random Forest
  - K-Nearest Neighbors (KNN)

Metodología

Comparación con Random Forest

- Se compara:
  - Elección real del estudiante vs. Predicción binaria del modelo (postula / no postula)

    Se obtiene:

    - Accuracy
    - Precision
    - Recall
    - F1-score
    - ROC-AUC

Metodología

Comparación con KNN(*k-Nearest Neighbors*)

- Recomienda carreras parecidas a las que el estudiante eligió.
- Funciona bien cuando los usuarios tienen varias interacciones.

Se obtiene:

- Precision@10
- Recall@10
- NDCG@10

Resultados

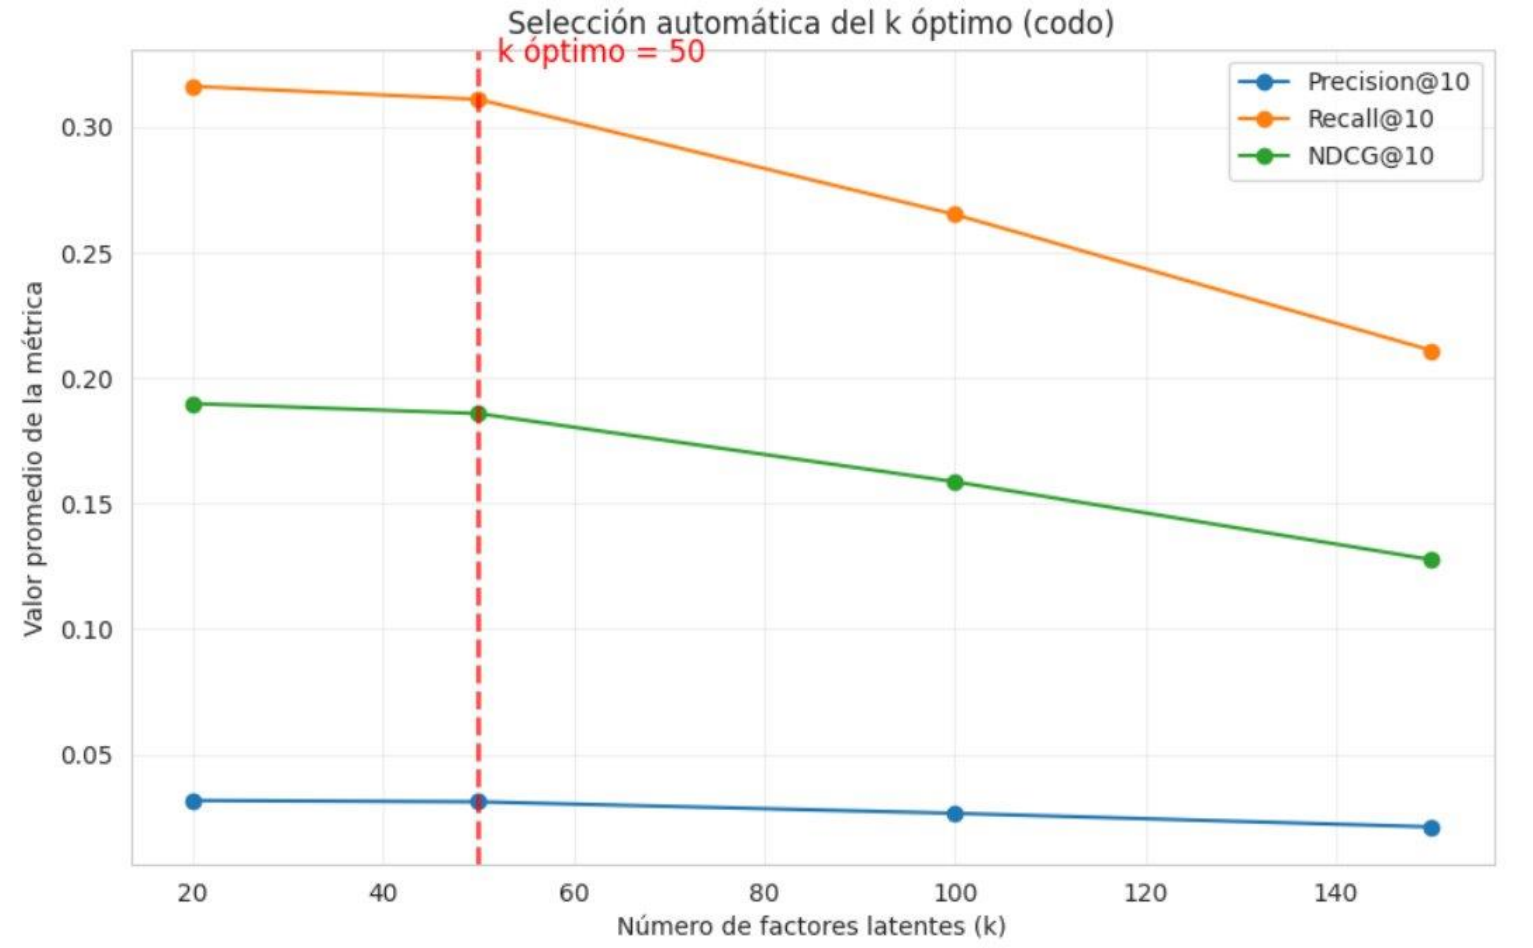

Selección del número de factores latentes

- Las métricas muestran que, al aumentar k, el desempeño mejora inicialmente y luego comienza a deteriorarse (sobreajuste)
- El método del codo identifica k = 50 como el valor óptimo

Resultados

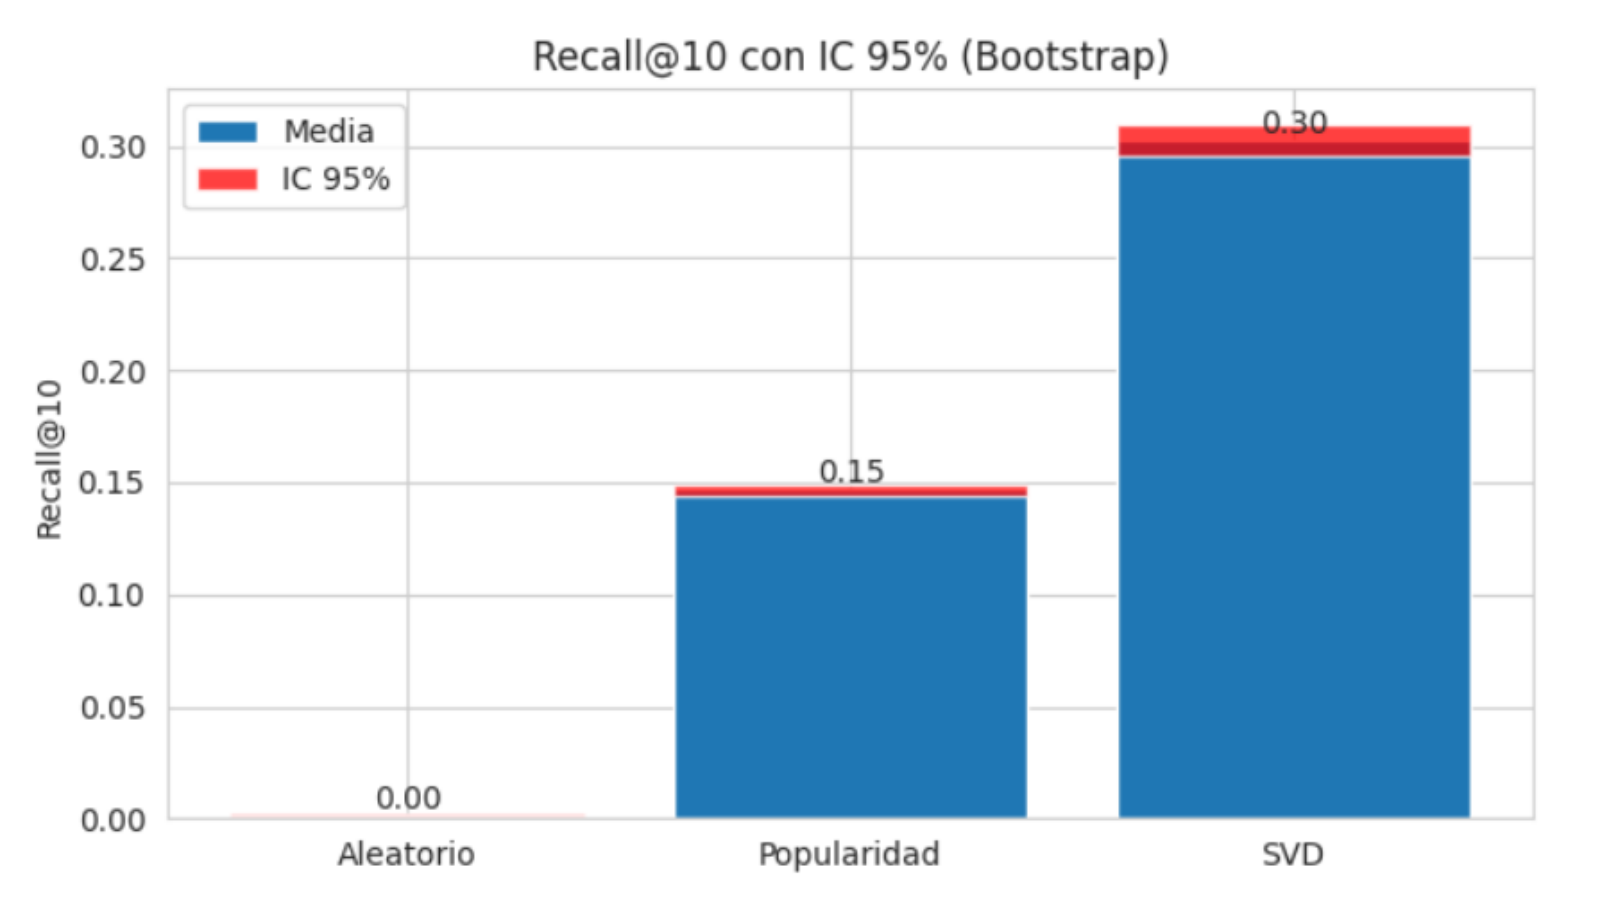

Comparación con baselines de recomendación con intervalo de confinaza

- El modelo SVD supera significativamente a ambos baselines.

Resultados

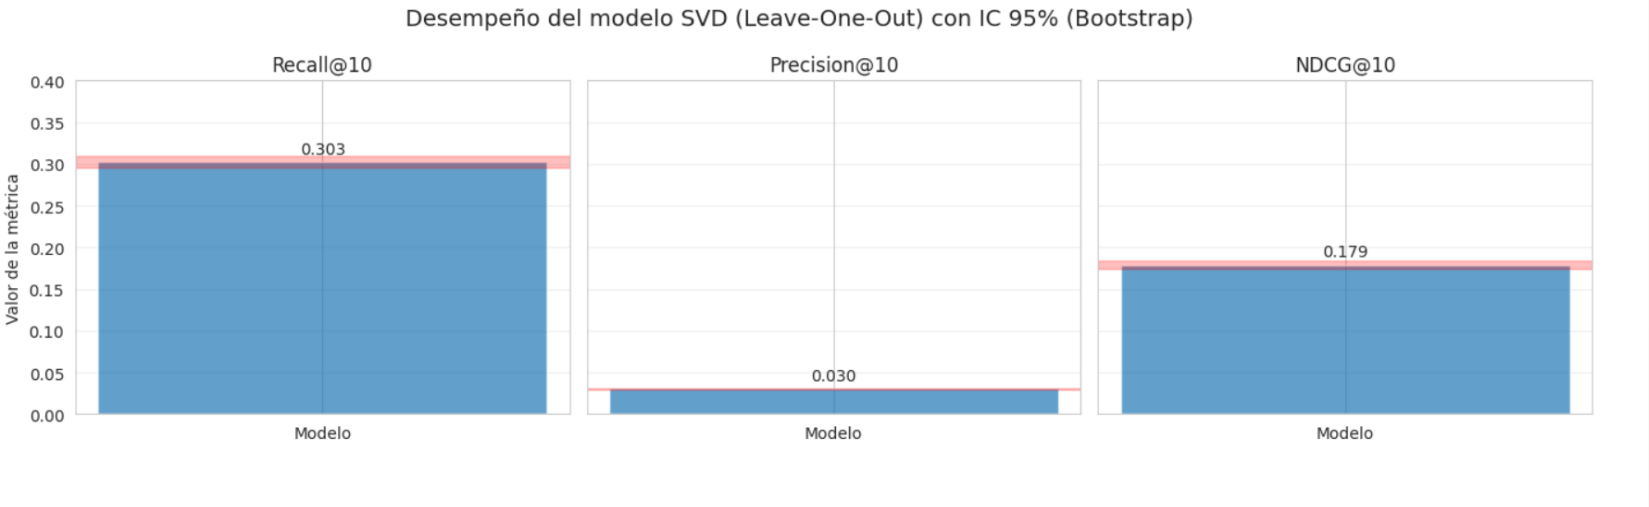

Evaluación del modelo SVD

- Recall@10 ≈ 0.30: en aproximadamente 3 de cada 10 estudiantes la carrera real aparece dentro del Top-10 de recomendaciones.
- Precision@10: de cada 10 recomendaciones, 0.0305 son aciertos en promedio.
- NDCG@10 ≈ 0.18: cuando el modelo acierta, la opción relevante suele aparecer en posiciones altas del ranking.

Resultados

IES_NOMBRE_INSTIT	CAR_NOMBRE_CARRERA	NOTA_POSTULA
UNIVERSIDAD CENTRAL DEL ECUADOR	PSICOLOGIA	816
UNIVERSIDAD CENTRAL DEL ECUADOR	PSICOLOGIA CLINICA	816
UNIVERSIDAD CENTRAL DEL ECUADOR	TERAPIA OCUPACIONAL	816
UNIVERSIDAD CENTRAL DEL ECUADOR	ENFERMERIA	816
UNIVERSIDAD CENTRAL DEL ECUADOR	ADMINISTRACION DE EMPRESAS	816
UNIVERSIDAD CENTRAL DEL ECUADOR	PSICOPEDAGOGIA	816
UNIVERSIDAD CENTRAL DEL ECUADOR	EDUCACION INICIAL	816

Comparativa entre Recomendaciones y Carrera Real del Estudiante:

	Rank	Instituto Recomendado	Carrera Recomendada	Coincide con carrera real
0	1	UNIVERSIDAD CENTRAL DEL ECUADOR	ATENCION PREHOSPITALARIA	✗ No
1	2	UNIVERSIDAD CENTRAL DEL ECUADOR	IMAGENOLOGIA Y RADIOLOGIA	✗ No
2	3	UNIVERSIDAD TECNICA DE AMBATO	PSICOLOGIA CLINICA	✔ Sí
3	4	UNIVERSIDAD CENTRAL DEL ECUADOR	BIOLOGIA	✗ No
4	5	UNIVERSIDAD CENTRAL DEL ECUADOR	SOCIOLOGIA	✗ No
5	6	UNIVERSIDAD CENTRAL DEL ECUADOR	CIENCIAS POLITICAS	✗ No
6	7	UNIVERSIDAD CENTRAL DEL ECUADOR	PEDAGOGIA DE LA LENGUA Y LA LITERATURA	✗ No
7	8	INSTITUTO TECNOLÓGICO SUPERIOR GUAYAQUIL	TECNOLOGIA SUPERIOR EN MARKETING	✗ No
8	9	UNIVERSIDAD CENTRAL DEL ECUADOR	COMUNICACION	✗ No
9	10	UNIVERSIDAD DE CUENCA	ODONTOLOGIA	✗ No

Ejemplo de recomendaciones individuales

- Se comparan:
  - Opción académica real
  - Top-10 recomendaciones generadas por el modelo.

Resultados

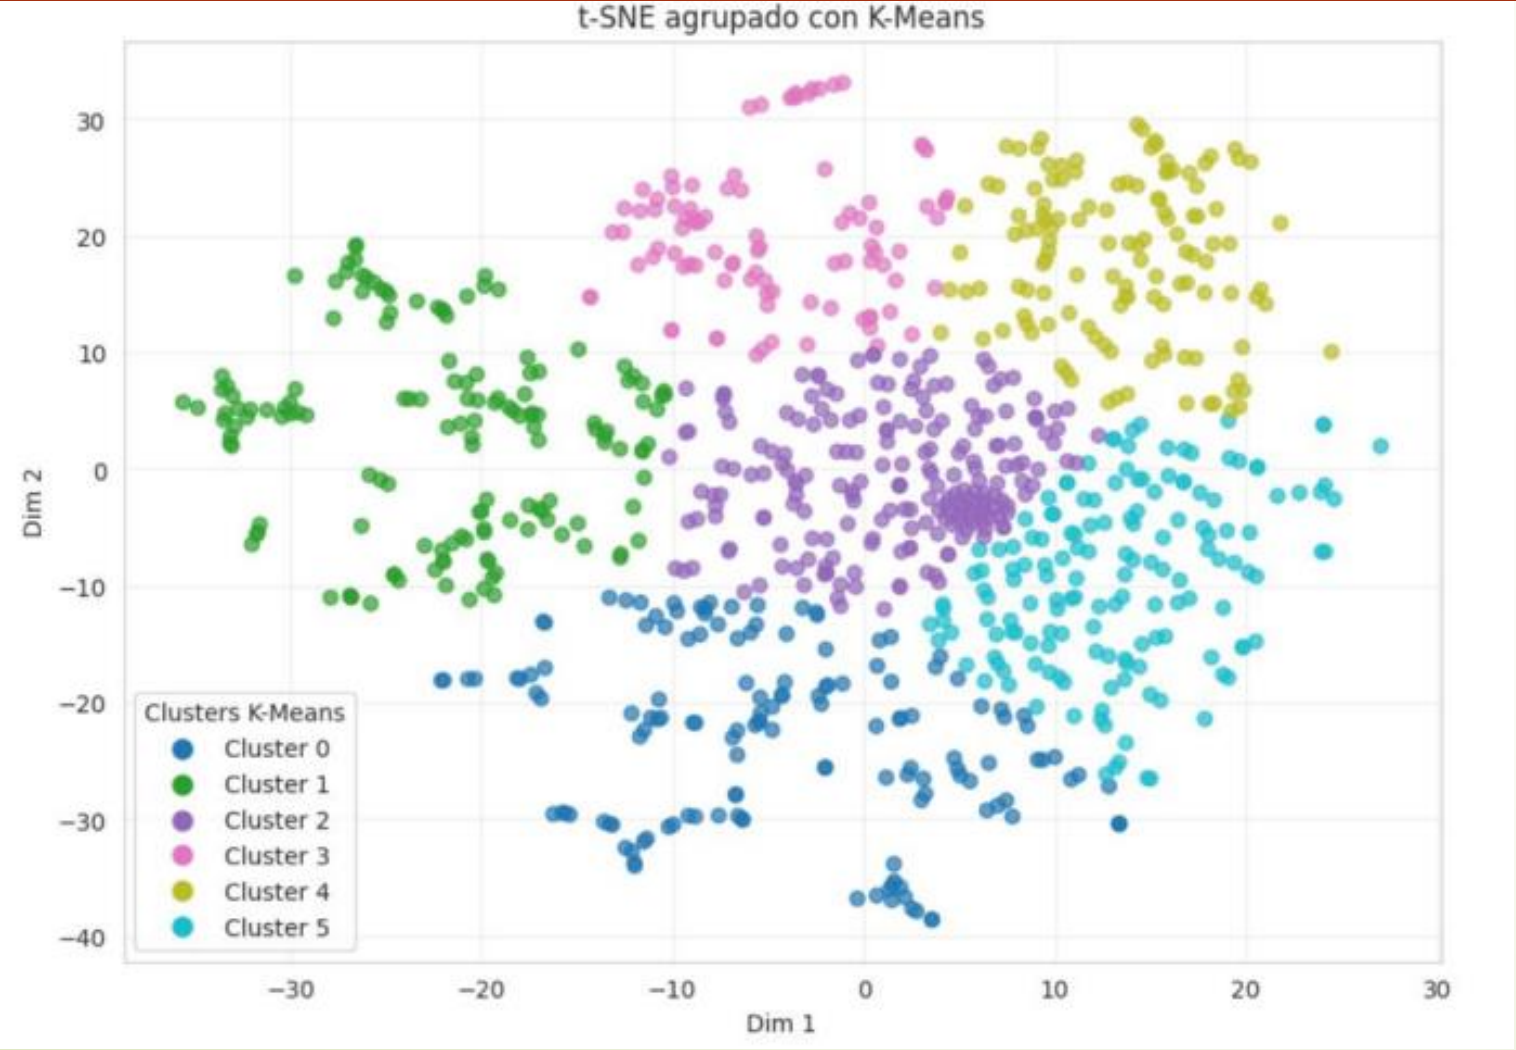

Análisis de factores latentes

- Se aplicó t-SNE para proyectar los factores latentes aprendidos por el modelo en dos dimensiones.
- Se utilizó K-Means para identificar agrupamientos de programas académicos.
- Los resultados muestran clusters de carreras e instituciones con patrones de postulación similares.
- Esto indica que el modelo SVD captura relaciones latentes entre programas académicos.

Resultados

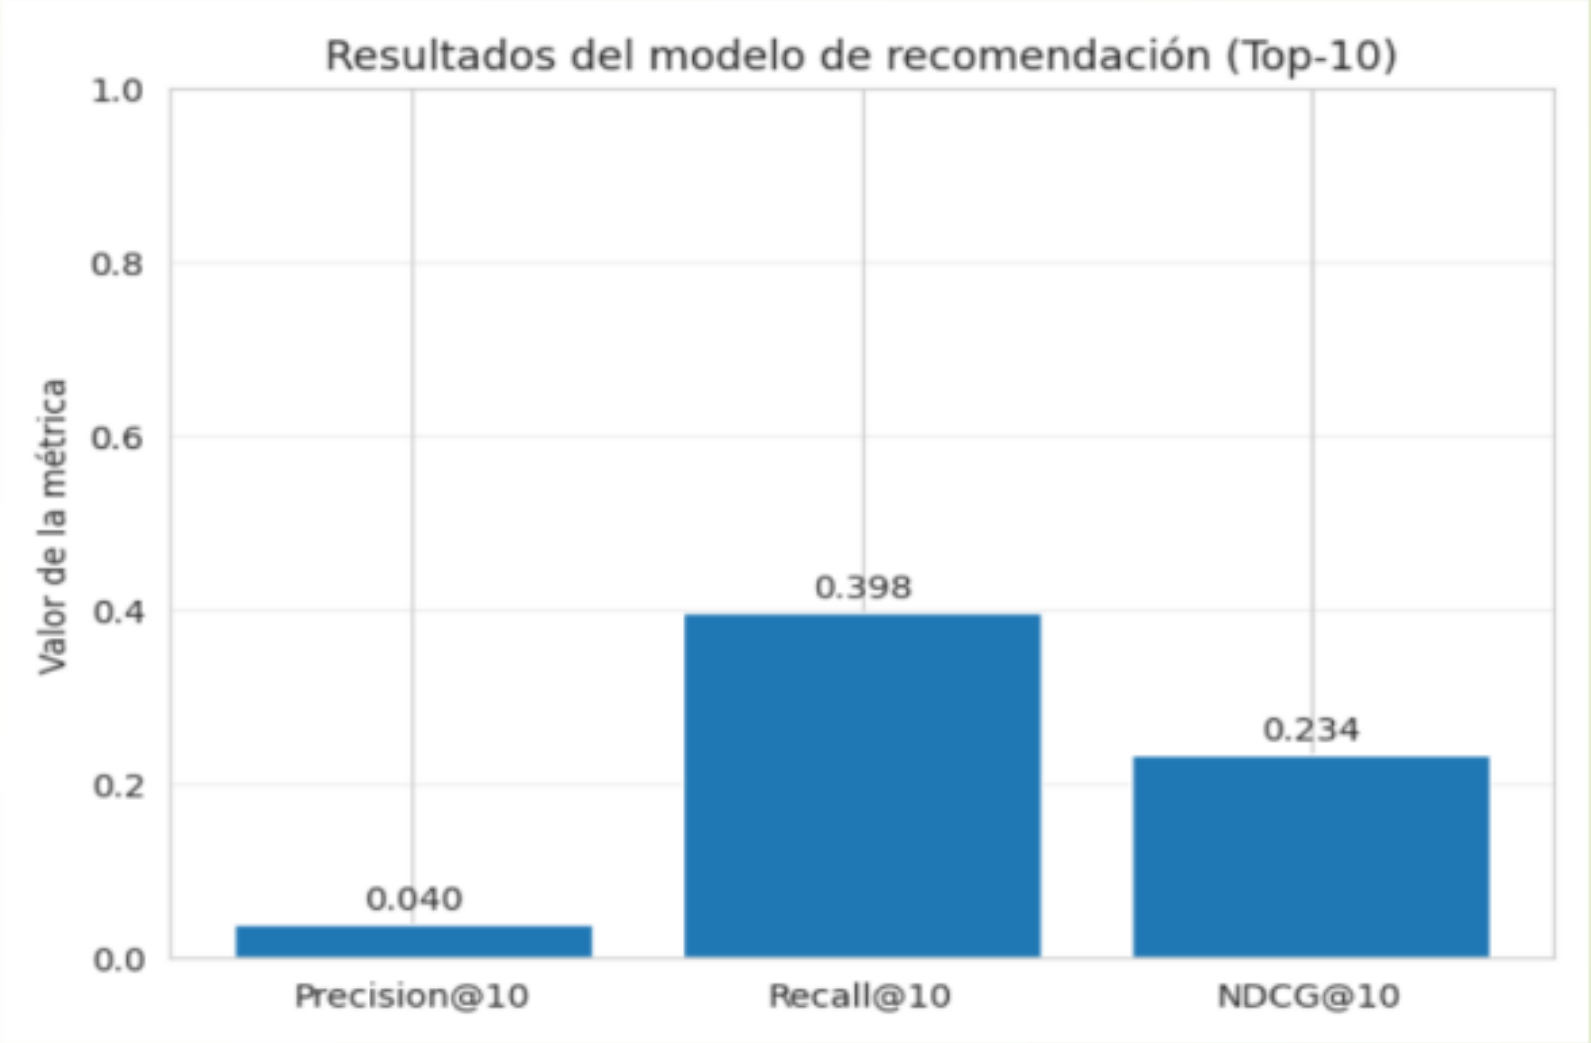

Incorporación de información contextual geográfica

- Se incorporaron variables adicionales al modelo:
  - Provincia de la institución
  - Nota de postulación
- Resultados
  - Recall@10: 0.30 → 0.40
  - NDCG@10: 0.18 → 0.23
  - Precision@10: ligera mejora

Limitaciones del estudio

- Aunque el modelo muestra buenos resultados, presenta limitaciones relacionadas con el uso de datos de un solo periodo y la ausencia de variables adicionales que podrían influir en la decisión académica. Además, la evaluación se basa en métricas técnicas, por lo que los resultados deben interpretarse como una validación metodológica del enfoque.

Conclusiones

- Se desarrolló un sistema de recomendación basado en SVD para apoyar la orientación académica en el proceso de admisión.
- El modelo logra capturar patrones latentes de preferencia en datos altamente dispersos.
- Se obtuvo un Recall@10 ≈ 30 %, evidenciando una buena capacidad para recuperar opciones relevantes.
- El modelo supera a métodos base y es adecuado para escenarios de retroalimentación implícita.
- La incorporación de información contextual mejora el desempeño y la relevancia de las recomendaciones.
- La propuesta es una solución escalable, interpretable y basada en datos para complementar la orientación vocacional.

Trabajos futuros

- Incorporar variables adicionales:
  - Nota alcanzada y nota mínima.
- Explorar modelos híbridos basados en:
  - SVD + variables del estudiante
  - SVD + características de los programas académicos
- Evaluar el sistema en un entorno real (pruebas A/B o estudios de usuario).